

Um Sistema de Segmentação de Clientes de Shopping baseado em K-Means com Seleção Criteriosa de Grupos e Geração de Personas Acionáveis

Grupo — IMD0029

Bacharelado em Tecnologia da Informação
Instituto Metrôple Digital (IMD), UFRN
Natal/RN, Brasil

Resumo—A segmentação de clientes é uma tarefa central no varejo, pois permite direcionar ações de marketing a grupos com comportamentos de consumo distintos. Este trabalho apresenta um sistema completo de segmentação — e não apenas a validação de um conjunto de dados — estruturado como um *pipeline* que recebe atributos demográficos e comportamentais de clientes e produz personas acionáveis. O núcleo do sistema é o algoritmo K-Means. Duas contribuições técnicas são destacadas: (i) a escolha do número de grupos k combinando três critérios independentes — método do cotovelo, coeficiente de silhueta e índice Calinski-Harabasz — de modo que a concordância gere confiança e a divergência se torne objeto de discussão; e (ii) a tradução de cada grupo em uma persona com recomendação de marketing. Aplicado ao *Mall Customer Segmentation Dataset* (200 clientes), o sistema identificou cinco perfis interpretáveis, com coeficiente de silhueta de 0,42, e gerou recomendações de negócio coerentes com a literatura.

Index Terms—aprendizado não-supervisionado, K-Means, segmentação de clientes, silhueta, PCA, personas.

I. INTRODUÇÃO

A capacidade de compreender o comportamento de compra dos consumidores tornou-se um diferencial competitivo para o varejo. Em vez de tratar a base de clientes como um todo homogêneo, as empresas buscam dividi-la em grupos com características semelhantes, prática conhecida como *segmentação de clientes*. Cada segmento pode então receber estratégias de marketing específicas, o que aumenta a efetividade das campanhas e a satisfação do cliente.

Como na prática não se conhecem previamente os rótulos dos segmentos, o problema é naturalmente abordado por técnicas de *aprendizado de máquina não-supervisionado*, em particular por algoritmos de agrupamento (*clustering*). O K-Means [1] é o método mais empregado nesse contexto por sua simplicidade, eficiência e interpretabilidade.

Entretanto, dois desafios práticos costumam ser subestimados. O primeiro é a definição do número de grupos k , parâmetro que o K-Means não infere automaticamente e que afeta diretamente a qualidade da solução. O segundo é a transformação dos grupos obtidos em informação útil para o negócio: um rótulo numérico de *cluster*, isoladamente, não orienta ações.

Este trabalho aborda ambos os desafios propondo um sistema de segmentação com *pipeline* bem definido. As contribuições são: (i) a seleção criteriosa de k por meio da combinação de três critérios complementares; e (ii) a geração automática de personas com recomendações de marketing a partir dos centroides. O sistema foi avaliado sobre o *Mall Customer Segmentation Dataset*.

II. TRABALHOS RELACIONADOS

O K-Means foi formalizado por MacQueen [1] e permanece, décadas depois, um dos algoritmos de agrupamento mais utilizados, sobretudo em aplicações de marketing e análise de clientes. Para a escolha de k , a literatura oferece critérios distintos: o método do cotovelo analisa a redução da inércia (soma das distâncias intra-grupo); o coeficiente de silhueta [2] mede o quão bem cada ponto se ajusta ao seu grupo em relação ao grupo vizinho mais próximo; e o índice de Calinski-Harabasz [3] avalia a razão entre a dispersão entre grupos e a dispersão interna. Cada critério captura um aspecto diferente da qualidade do agrupamento, o que motiva seu uso conjunto.

Para visualização de dados de alta dimensão, a Análise de Componentes Principais (PCA) [4] é amplamente adotada, projetando os dados em poucas dimensões que preservam o máximo de variância. As implementações utilizadas neste trabalho provêm da biblioteca *scikit-learn* [5]. Em comparação com trabalhos que se limitam a aplicar o K-Means e reportar métricas, o presente sistema agrega uma etapa de decisão multicritério para k e uma camada de saída orientada ao negócio.

III. METODOLOGIA

O sistema proposto foi concebido como um *pipeline* de processamento que transforma dados brutos de clientes em personas acionáveis. A Fig. 1 apresenta a arquitetura, composta por seis estágios.

A. Entrada e pré-processamento

A entrada é composta por três atributos por cliente: idade, renda anual e *spending score* (índice de gasto de 1 a 100).




Figura 1. Arquitetura do sistema de segmentação. Diagrama elaborado pelos autores (Matplotlib).

Como esses atributos possuem escalas distintas e o K-Means se baseia em distância euclidiana, aplica-se padronização *z-score*, de modo que cada atributo passe a ter média zero e desvio-padrão unitário, evitando que a variável de maior amplitude domine o agrupamento.

B. Seleção do número de grupos

O K-Means minimiza a inércia

$$J = \sum_{i=1}^n \min_{\mu_j \in C} \|x_i - \mu_j\|^2, \quad (1)$$

onde x_i é a i -ésima amostra e μ_j o centroide do grupo C_j . Para escolher k , varia-se $k \in \{2, \dots, 10\}$ e, para cada valor, calculam-se: a inércia (cotovelo), o coeficiente de silhueta [2] e o índice de Calinski-Harabasz [3]. A decisão final pondera os três critérios: quando convergem, a escolha ganha confiança; quando divergem, a divergência é analisada à luz da interpretabilidade dos grupos.

C. Agrupamento e visualização

Definido k , executa-se o K-Means com 50 inicializações (*k-means++*) e semente fixa para reprodutibilidade. Para visualizar os grupos, projeta-se o espaço padronizado de três dimensões em duas componentes principais via PCA [4].

D. Geração de personas

Cada grupo é caracterizado pelas médias de seus atributos (centroide em escala original). A partir desse perfil, o sistema atribui um nome descritivo e uma recomendação de marketing, traduzindo o resultado estatístico em ação de negócio (p. ex., alta renda e alto gasto $\rightarrow$ programa *premium*).

E. Materiais

O sistema foi implementado em Python com *scikit-learn* [5], *pandas* e *matplotlib*. Utilizou-se o *Mall Customer Segmentation Dataset*, com 200 clientes.

IV. EXPERIMENTOS

O experimento principal consistiu em executar o *pipeline* completo sobre o conjunto de dados e avaliar os três critérios de seleção de k . A Tabela I consolida os valores obtidos; a Fig. 2 mostra as curvas correspondentes. Em seguida, fixou-se k e analisou-se a separação dos grupos no espaço PCA e os perfis resultantes.

Tabela I
CRITÉRIOS DE SELEÇÃO DE k (VALORES EM NEGRITO INDICAM O ÓTIMO DE CADA CRITÉRIO).

k	Inércia (WCSS)	Silhueta	Calinski-Harabasz
2	389,39	0,3355	107,10
3	295,21	0,3578	101,69
4	205,23	0,4040	125,68
5	168,25	0,4166	125,10
6	133,87	0,4274	135,10
7	117,01	0,4172	132,77
8	103,83	0,4087	131,07
9	92,35	0,4201	131,24
10	81,99	0,3973	133,38




Figura 2. Critérios para seleção de k : (a) cotovelo, (b) silhueta e (c) Calinski-Harabasz. Linhas tracejadas marcam pontos de interesse. Figura elaborada pelos autores.

V. RESULTADOS E DISCUSSÃO

A. Escolha de k e divergência entre critérios

Os critérios não foram unânimes. O método do cotovelo (Fig. 2a) exibe inflexão clara em torno de $k = 5$, ponto a partir do qual a redução da inércia desacelera. Já a silhueta e o índice Calinski-Harabasz atingem máximo em $k = 6$ (Tabela I), embora a diferença para $k = 5$ seja pequena (silhueta 0,4274 contra 0,4166). Trata-se justamente do cenário de *divergência* previsto no projeto: optou-se por $k = 5$, pois o ganho marginal em $k = 6$ é modesto e os cinco grupos resultantes possuem interpretação de negócio mais nítida, ao passo que o sexto grupo tende a subdividir um perfil já coeso. Essa escolha privilegia a parcimônia e a acionabilidade sem perda relevante de qualidade numérica.

B. Estrutura dos grupos

A Fig. 3 mostra os grupos projetados nas duas primeiras componentes principais, que retêm 77,6% da variância total (44,3% e 33,3%). Os grupos aparecem bem delimitados, com centroides distantes entre si, o que corrobora a coesão indicada pela silhueta de 0,42 obtida em $k = 5$.

C. Personas acionáveis

A Tabela II traduz cada centroide em uma persona com recomendação de marketing. O sistema distingue, por exemplo, clientes de alta renda com alto gasto (alvo de programas *premium*) de clientes de alta renda com baixo gasto (alvo de campanhas de conversão), perfis que exigem estratégias opostas apesar de renda semelhante.

Tabela II
PERSONAS GERADAS A PARTIR DOS CENTROIDES ($k = 5$). VALORES MÉDIOS EM ESCALA ORIGINAL.

Grupo	Persona	Idade	Renda (k\$)	Gasto	N	Recomendação de marketing
0	Maduro econômico	46,2	26,8	18,4	20	Ofertas de baixo custo e descontos sazonais; baixa prioridade de investimento.
1	Jovem entusiasta	25,2	41,1	62,2	54	Programa de fidelidade e engajamento digital; alto potencial de longo prazo.
2	<i>Premium</i> ativo	32,9	86,1	81,5	40	Serviços exclusivos, lançamentos e <i>cross-selling</i> de alto valor.
3	Conservador endinheirado	39,9	86,1	19,4	39	Campanhas de conversão e benefícios para estimular gasto; foco em confiança.
4	Público médio	55,6	54,4	48,9	47	Comunicação equilibrada e promoções generalistas; segmento de manutenção.




Figura 3. Grupos no espaço das duas primeiras componentes principais (PCA), com centroides destacados. Figura elaborada pelos autores.

D. Limitações

O sistema usa apenas três atributos e um conjunto de dados de pequeno porte (200 clientes). O K-Means assume grupos aproximadamente esféricos e é sensível a *outliers*. Trabalhos futuros podem incorporar mais atributos comportamentais, comparar com algoritmos baseados em densidade e validar as personas com dados reais de campanha.

VI. CONCLUSÃO

Apresentou-se um sistema de segmentação de clientes estruturado como *pipeline*, cujo núcleo é o K-Means. As duas contribuições — seleção de k por três critérios e geração de personas acionáveis — mostraram-se efetivas: o sistema produziu cinco perfis interpretáveis (silhueta 0,42) e recomendações de marketing coerentes. O caso de divergência entre critérios ($k = 5$ vs. $k = 6$) evidenciou o valor da abordagem multicritério, que combina evidência numérica e interpretabilidade na decisão final.

REFERÊNCIAS

- [1] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, vol. 1, 1967, pp. 281–297.
- [2] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

- [3] T. Caliński and J. Harabasz, “A dendrite method for cluster analysis,” *Commun. Statist.*, vol. 3, no. 1, pp. 1–27, 1974.
- [4] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. New York: Springer, 2002.
- [5] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

ANEXO — DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Ferramenta utilizada: assistente de IA baseado em modelo de linguagem (Claude, Anthropic).

Finalidade do uso: apoio à estruturação textual do artigo, revisão de escrita acadêmica e auxílio na organização do *pipeline* experimental.

Forma de utilização: a ferramenta foi empregada na redação e revisão do texto e na geração do código do experimento, que foi executado e verificado pelos autores. Todos os resultados numéricos (Tabelas I e II) e as figuras foram produzidos pela execução do código sobre o conjunto de dados real e conferidos pelo grupo. Os diagramas e gráficos (Figs. 1–3) foram gerados programaticamente com a biblioteca Matplotlib, possuindo legenda e numeração; o conteúdo conceitual associado está referenciado na bibliografia. A decisão metodológica final e a interpretação dos resultados são de responsabilidade dos autores.