

Um Sistema de Segmentação de Clientes de Shopping baseado em K-Means com Seleção Criteriosa de Grupos e Geração de Personas Acionáveis

Chistian Daniel Pereira da Silva
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Enock Gomes Neto
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Esdras Felipe Chaves Pinto Nascimento e Silva
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Gabriel Santos da Silveira
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Glauco Ezequiel de Sousa Gonçalves
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Vitor Fraifer Palhano dos Anjos
Bacharelado em Tecnologia da Informação
Instituto Metrópole Digital (IMD), UFRN
Natal/RN, Brasil

Resumo—A segmentação de clientes é uma tarefa central no varejo, pois permite direcionar ações de marketing a grupos com comportamentos de consumo distintos. Este trabalho apresenta um sistema completo de segmentação, e não apenas a validação de um conjunto de dados, estruturado como um *pipeline* que recebe atributos demográficos e comportamentais de clientes e produz personas acionáveis. O núcleo do sistema é o algoritmo K-Means. Destacam-se duas contribuições técnicas. A primeira é a escolha do número de grupos k a partir de três critérios independentes (método do cotovelo, coeficiente de silhueta e índice Calinski-Harabasz), de forma que a concordância entre eles reforça a confiança na escolha e a divergência abre espaço para discussão. A segunda é a tradução de cada grupo em uma persona com recomendação de marketing. Aplicado ao *Mall Customer Segmentation Dataset*, com 200 clientes, o sistema identificou cinco perfis interpretáveis, com coeficiente de silhueta de 0,42, e gerou recomendações de negócio coerentes com a literatura.

Index Terms—aprendizado não-supervisionado, K-Means, segmentação de clientes, silhueta, PCA, personas.

I. INTRODUÇÃO

Compreender o comportamento de compra dos consumidores tornou-se um diferencial competitivo para o varejo. Em vez de tratar a base de clientes como um bloco homogêneo, as empresas procuram dividi-la em grupos de características semelhantes, prática conhecida como *segmentação de clientes*. Com os grupos em mãos, cada segmento pode receber es-

tratégias de marketing próprias, o que tende a aumentar a efetividade das campanhas e a satisfação do cliente.

Na prática, os rótulos dos segmentos não são conhecidos de antemão. Por isso, o problema costuma ser tratado com técnicas de *aprendizado de máquina não-supervisionado*, em especial por algoritmos de agrupamento (*clustering*). O K-Means [1] é o método mais usado nesse cenário, graças à simplicidade, à eficiência e à facilidade de interpretação dos resultados.

Dois desafios práticos, porém, costumam ser subestimados. O primeiro é definir o número de grupos k , parâmetro que o K-Means não descobre sozinho e que influencia diretamente a qualidade da solução. O segundo é transformar os grupos obtidos em informação útil para o negócio, já que um rótulo numérico de *cluster*, sozinho, não indica que ação tomar.

Este trabalho enfrenta os dois desafios com um sistema de segmentação apoiado em um *pipeline* bem definido. As contribuições são a seleção criteriosa de k , que combina três critérios complementares, e a geração automática de personas com recomendações de marketing a partir dos centroides. A avaliação foi feita sobre o *Mall Customer Segmentation Dataset*.

II. TRABALHOS RELACIONADOS

O K-Means foi formalizado por MacQueen [1] e, décadas depois, segue entre os algoritmos de agrupamento mais utilizados, sobretudo em marketing e análise de clientes. Para escolher k , a literatura oferece critérios com focos diferentes.




Figura 1. Arquitetura do sistema de segmentação, do dado bruto do cliente até a saída acionável. Diagrama elaborado pelos autores (Matplotlib).

O método do cotovelo observa a redução da inércia, isto é, da soma das distâncias internas aos grupos. O coeficiente de silhueta [2] mede o quão bem cada ponto se encaixa no seu grupo em comparação com o grupo vizinho mais próximo. Já o índice de Calinski-Harabasz [3] compara a dispersão entre grupos com a dispersão interna. Como cada critério enxerga um aspecto distinto da qualidade do agrupamento, faz sentido usá-los em conjunto.

Para visualizar dados de alta dimensão, a Análise de Componentes Principais (PCA) [4] é largamente empregada, pois projeta os dados em poucas dimensões preservando o máximo de variância. Neste trabalho, as implementações vêm da biblioteca *scikit-learn* [5]. Diferentemente de estudos que apenas aplicam o K-Means e relatam métricas, o sistema aqui proposto acrescenta uma etapa de decisão multicritério para k e uma camada de saída voltada ao negócio.

A. Por que K-Means

O K-Means não é a única opção de agrupamento. O DBSCAN forma grupos a partir da densidade dos pontos, dispensa a definição prévia de k e identifica *outliers* de forma natural, mas seu desempenho depende muito dos parâmetros de vizinhança (ε e número mínimo de pontos) e tende a sofrer quando os grupos têm densidades bem diferentes. Já o agrupamento hierárquico produz um dendrograma que revela a estrutura em vários níveis e também não exige k de antemão, porém tem custo computacional mais alto e não escala tão bem para bases maiores.

Para o problema tratado aqui, o K-Means reúne as vantagens que mais importam: os atributos de cliente formam grupos relativamente compactos e de tamanho comparável, situação em que o método costuma ir bem; o resultado é um centroide por grupo, o que se traduz com facilidade em uma persona; e o baixo custo permite repetir o algoritmo para vários valores de k durante a seleção. A ausência de definição automática de k , principal limitação do método, é justamente o que a etapa multicritério descrita adiante busca contornar.

III. METODOLOGIA

O sistema foi concebido como um *pipeline* que transforma dados brutos de clientes em personas acionáveis. A Fig. 1 mostra a arquitetura, formada por seis estágios.

Algorithm 1 K-Means

Require: dados $X = \{x_1, \dots, x_n\}$, número de grupos k

Ensure: atribuições de grupo e centroides $\{\mu_1, \dots, \mu_k\}$

- 1: inicializar k centroides (*k-means++*)
- 2: **repeat**
- 3: **Atribuição:** associar cada x_i ao centroide μ_j mais próximo
- 4: **Atualização:** recalculer cada μ_j como a média dos pontos do grupo C_j
- 5: **until** os centroides não mudarem (convergência)
- 6: **return** atribuições e centroides

A. Entrada e pré-processamento

A entrada reúne três atributos por cliente: idade, renda anual e *spending score* (índice de gasto de 1 a 100). Esses atributos estão em escalas diferentes, e o K-Means se baseia em distância euclidiana. Para que a variável de maior amplitude não domine o agrupamento, aplica-se a padronização *z-score*, deixando cada atributo com média zero e desvio-padrão unitário.

B. O algoritmo K-Means

O K-Means particiona as amostras em k grupos buscando minimizar a inércia,

$$J = \sum_{i=1}^n \min_{\mu_j \in C} \|x_i - \mu_j\|^2, \quad (1)$$

em que x_i é a i -ésima amostra e μ_j é o centroide do grupo C_j . O algoritmo parte de centroides iniciais e repete dois passos até estabilizar: atribui cada ponto ao centroide mais próximo e, em seguida, recalcula cada centroide como a média dos pontos que lhe foram atribuídos. O Algoritmo 1 resume esse procedimento, e a Fig. 2 ilustra esse processo, da posição inicial dos centroides até a convergência, quando as atribuições deixam de mudar.

C. Seleção do número de grupos

A escolha de k varre o intervalo $k \in \{2, \dots, 10\}$. Para cada valor, calculam-se a inércia (cotovelo), o coeficiente de silhueta [2] e o índice de Calinski-Harabasz [3]. A decisão final pondera os três critérios: quando eles apontam para




Figura 2. Funcionamento do K-Means em dados ilustrativos: (a) centroides iniciais, (b) atribuição de cada ponto ao centroide mais próximo, (c) atualização dos centroides para a média dos pontos (setas indicam o deslocamento) e (d) configuração após a convergência. Figura elaborada pelos autores.

o mesmo k , a escolha ganha confiança; quando discordam, a divergência é examinada à luz da interpretabilidade dos grupos.

D. Agrupamento e visualização

Com k fixado, o K-Means é executado com 50 inicializações (*k-means++*) e semente fixa, o que garante reprodutibilidade. Na varredura de k , usam-se 20 inicializações por valor, um equilíbrio entre custo computacional e estabilidade; o modelo final adota 50 para refinar o resultado escolhido. Para visualizar os grupos, o espaço padronizado de três dimensões é projetado em duas componentes principais via PCA [4].

E. Geração de personas

Cada grupo é descrito pelas médias de seus atributos, ou seja, pelo centroide em escala original. A partir desse perfil, o sistema atribui um nome descritivo e uma recomendação de marketing, convertendo o resultado estatístico em uma ação de negócio. Um cliente de alta renda e alto gasto, por exemplo, aponta para um programa *premium*.

F. Materiais

O sistema foi implementado em Python, com *scikit-learn* [5], *pandas* e *matplotlib*. Os experimentos usaram o *Mall Customer Segmentation Dataset*, com 200 clientes.

IV. EXPERIMENTOS

A. Caracterização do conjunto de dados

Antes do agrupamento, examinaram-se as distribuições dos atributos. O conjunto reúne 200 clientes, sendo 112 do sexo feminino e 88 do masculino. A Tabela I resume as estatísticas descritivas dos três atributos usados. A idade varia de 18 a 70 anos, com média próxima de 39. A renda anual vai de 15 a 137 (em milhares), com média em torno de 61. O *spending score* cobre quase toda a faixa possível, de 1 a 99, com média de 50 e distribuição bastante espalhada (desvio-padrão de 26). Essa dispersão ampla em renda e gasto é o que torna o conjunto interessante para segmentação: há margem para perfis bem distintos, em vez de uma massa homogênea de clientes.

B. Procedimento experimental

O experimento principal executou o *pipeline* completo sobre o conjunto de dados e avaliou os três critérios de seleção de k . A Tabela II reúne os valores obtidos, e as Figs. 3 a 5 mostram as curvas de cada critério. Em seguida, com k

Tabela I
ESTATÍSTICAS DESCRITIVAS DOS ATRIBUTOS ($n = 200$).

	Idade	Renda (k\$)	Gasto (1–100)
Média	38,8	60,6	50,2
Desvio-padrão	14,0	26,3	25,8
Mínimo	18,0	15,0	1,0
1º quartil	28,8	41,5	34,8
Mediana	36,0	61,5	50,0
3º quartil	49,0	78,0	73,0
Máximo	70,0	137,0	99,0

Tabela II
CRITÉRIOS DE SELEÇÃO DE k . OS VALORES EM NEGRITO INDICAM O ÓTIMO DE CADA CRITÉRIO: COTOVELO EM $k = 5$; SILHUETA E CALINSKI-HARABASZ EM $k = 6$.

k	Inércia (WCSS)	Silhueta	Calinski-Harabasz
2	389,39	0,3355	107,10
3	295,21	0,3578	101,69
4	205,23	0,4040	125,68
5	168,25	0,4166	125,10
6	133,87	0,4274	135,10
7	117,01	0,4172	132,77
8	103,83	0,4087	131,07
9	92,35	0,4201	131,24
10	81,99	0,3973	133,38

fixado, analisaram-se a separação dos grupos no espaço PCA e os perfis resultantes.

V. RESULTADOS E DISCUSSÃO

A. Escolha de k e divergência entre critérios

Os critérios não foram unânimes. O método do cotovelo (Fig. 3) mostra uma inflexão clara em torno de $k = 5$, a partir da qual a inércia cai mais devagar. A silhueta (Fig. 4) e o índice Calinski-Harabasz (Fig. 5) atingem o máximo em $k = 6$, embora a vantagem sobre $k = 5$ seja pequena (silhueta de 0,4274 contra 0,4166). Esse é exatamente o tipo de divergência que o projeto previa. Optou-se por $k = 5$, porque o ganho em $k = 6$ é modesto e os cinco grupos têm leitura de negócio mais nítida; o sexto grupo, na prática, apenas reparte um perfil que já era coeso. A escolha favorece a simplicidade e a acionabilidade sem perda relevante de qualidade numérica.

Vale situar esse resultado na escala de Rousseeuw [2], que considera valores de silhueta entre 0,41 e 0,60 como indicio de estrutura moderada a boa. O coeficiente obtido (0,42 em $k = 5$ e 0,43 em $k = 6$) fica nessa faixa e acompanha o que reportam trabalhos que aplicam K-Means a dados demográficos e comportamentais de porte parecido [6], [7].

B. Estrutura dos grupos

A Fig. 6 apresenta os grupos projetados nas duas primeiras componentes principais, que preservam 77,6% da variância total (44,3% e 33,3%). Os grupos aparecem bem delimitados, com centroides afastados uns dos outros, o que confirma a coesão sugerida pela silhueta de 0,42 em $k = 5$.




Figura 3. Método do cotovelo. A redução da inércia perde ritmo a partir de $k = 5$, ponto destacado pela linha tracejada. Figura elaborada pelos autores.




Figura 5. Índice de Calinski-Harabasz em função de k , com máximo em $k = 6$. Figura elaborada pelos autores.




Figura 4. Coeficiente de silhueta em função de k . O valor máximo ocorre em $k = 6$, com $k = 5$ bastante próximo. Figura elaborada pelos autores.




Figura 6. Grupos no espaço das duas primeiras componentes principais (PCA), com os centroides destacados. Figura elaborada pelos autores.

C. Personas acionáveis

A Tabela III converte cada centroide em uma persona acompanhada de recomendação de marketing. Para situar os perfis, vale lembrar que, no conjunto como um todo, a idade média é de cerca de 39 anos, a renda anual média gira em torno de 60 mil e o *spending score* médio fica próximo de 50.

O grupo 2, *Premium ativo*, reúne os clientes mais valiosos: renda alta (média de 86) combinada com gasto elevado (81).

São o público ideal para serviços exclusivos e *cross-selling* de produtos de maior valor. O grupo 3, *Conservador endinheirado*, chama atenção por ter a mesma renda alta, mas gasto baixo (19); o desafio aqui não é poder de compra, e sim convencer o cliente a gastar, o que pede campanhas de conversão e construção de confiança. O contraste entre esses dois grupos reforça a ideia central do trabalho: a renda, isolada, não basta para orientar a ação de marketing.

Tabela III
PERSONAS GERADAS A PARTIR DOS CENTROIDES ($k = 5$). VALORES MÉDIOS EM ESCALA ORIGINAL.

Grupo	Persona	Idade	Renda (k\$)	Gasto	N	Recomendação de marketing
0	Maduro econômico	46,2	26,8	18,4	20	Ofertas de baixo custo e descontos sazonais; baixa prioridade de investimento.
1	Jovem entusiasta	25,2	41,1	62,2	54	Programa de fidelidade e engajamento digital; alto potencial de longo prazo.
2	<i>Premium</i> ativo	32,9	86,1	81,5	40	Serviços exclusivos, lançamentos e <i>cross-selling</i> de alto valor.
3	Conservador endinheirado	39,9	86,1	19,4	39	Campanhas de conversão e benefícios para estimular gasto; foco em confiança.
4	Público médio	55,6	54,4	48,9	47	Comunicação equilibrada e promoções generalistas; segmento de manutenção.

O grupo 1, *Jovem entusiasta*, é o mais numeroso (54 clientes) e mistura idade baixa (25 anos) com gasto acima da média, apesar de renda apenas mediana; é um público de alto potencial no longo prazo, bom alvo para programas de fidelidade e engajamento digital. No extremo oposto, o grupo 0, *Maduro econômico*, junta a renda mais baixa (27) ao menor gasto (18), o que justifica priorizar ofertas de baixo custo sem grande investimento. Por fim, o grupo 4, *Público médio*, ocupa a posição intermediária em todos os atributos e funciona como um segmento de manutenção, atendido por comunicação mais generalista.

D. Limitações

O sistema usa apenas três atributos e um conjunto de dados pequeno, com 200 clientes. Além disso, o K-Means pressupõe grupos aproximadamente esféricos e sofre influência de *outliers*. Em trabalhos futuros, pretende-se incorporar mais atributos comportamentais, comparar o método com algoritmos baseados em densidade e validar as personas com dados reais de campanha.

VI. CONCLUSÃO

Este trabalho apresentou um sistema de segmentação de clientes organizado como *pipeline* e centrado no K-Means. As duas contribuições propostas, a seleção de k por três critérios e a geração de personas acionáveis, mostraram-se eficazes: o sistema produziu cinco perfis interpretáveis, com silhueta de 0,42, e recomendações de marketing coerentes. A divergência entre critérios ($k = 5$ contra $k = 6$) reforçou o valor da abordagem multicritério, que une evidência numérica e interpretabilidade no momento de decidir.

REFERÊNCIAS

- [1] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symp. Math. Statist. Probab.*, vol. 1, 1967, pp. 281–297.
- [2] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.
- [3] T. Caliński and J. Harabasz, "A dendrite method for cluster analysis," *Commun. Statist.*, vol. 3, no. 1, pp. 1–27, 1974.
- [4] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. New York: Springer, 2002.
- [5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [6] K. P. Sinaga and M.-S. Yang, "Unsupervised K-means clustering algorithm," *IEEE Access*, vol. 8, pp. 80436–80451, 2020.
- [7] C. P. Ezenkwu, S. Ozuomba, and C. Kalu, "Application of K-Means algorithm for efficient customer segmentation: A strategy for targeted customer services," *Int. J. Adv. Res. Artif. Intell.*, vol. 4, no. 10, pp. 40–44, 2015.

ANEXO — DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Ferramenta utilizada: assistente de IA baseado em modelo de linguagem (Claude, Anthropic).

Finalidade do uso: revisão gramatical e ortográfica do texto redigido pelos autores, organização de ideias e auxílio no código Python do *pipeline* experimental.

Forma de utilização: o texto do artigo foi elaborado pelos integrantes do grupo; a ferramenta foi utilizada para revisão

e sugestões de melhoria de escrita, sem geração automática de conteúdo. No código, a IA auxiliou na organização do *pipeline*, que foi executado e verificado pelos autores. Todos os resultados numéricos (Tabelas I, II e III) e as figuras foram produzidos pela execução do código sobre o conjunto de dados real e conferidos pelo grupo. Os diagramas e gráficos (Figs. 1, 2 e 3–6) foram gerados programaticamente com a biblioteca Matplotlib, possuindo legenda e numeração; o conteúdo conceitual associado está referenciado na bibliografia. A decisão metodológica final e a interpretação dos resultados são de responsabilidade dos autores.